

# Проекты Международной лаборатории языковой конвергенции

Семинар Школы лингвистики

Г. А. Мороз

30.01.2026

# О лаборатории

## Международная лаборатория языковой конвергенции

- Открыта в 2017 году



(а) Н. Р. Добрушина



(а) Дж. Николс

Оба исследователя специализируются на славянских языках и языках Кавказа, а также лингвистической типологии

## Ресурсы лаборатории

### У истоков проекта

- Многолетние социолингвистические поездки в Дагестан
- Несколько диалектных экспедиций в Устьянский район
- Онлайн ресурсы, появившиеся в результате:
  - Корпус дагестанского русского
  - Корпус устьянских говоров
  - ... другие диалектные и билингвальные корпуса

## Ресурсы лаборатории

### У истоков проекта

- Многолетние социолингвистические поездки в Дагестан
- Несколько диалектных экспедиций в Устьянский район
- Онлайн ресурсы, появившиеся в результате:
  - Корпус дагестанского русского
  - Корпус устьянских говоров
  - ... другие диалектные и билингвальные корпуса

### Сейчас

- <https://lingconlab.ru/>
- 28 диалектных корпусов
- 10 билингвальных корпусов
- 17 корпусов языков России
- 6 словарей языков России
- 8 лингвистических баз данных

## Ресурсы лаборатории

### У истоков проекта

- Многолетние социолингвистические поездки в Дагестан
- Несколько диалектных экспедиций в Устьянский район
- Онлайн ресурсы, появившиеся в результате:
  - Корпус дагестанского русского
  - Корпус устьянских говоров
  - ... другие диалектные и билингвальные корпуса

### Сейчас

- <https://lingconlab.ru/>
- 28 диалектных корпусов
- 10 билингвальных корпусов
- 17 корпусов языков России
- 6 словарей языков России
- 8 лингвистических баз данных

И мы ищем людей, которые бы все это поддерживали!

## Наши исследования

- Исследования диалектных и нестандартных вариантов русского языка
- Документация и исследования языков Кавказа
- Ассирийские исследования
- Типологические и микротипологические исследования
- Есть потенциал для исследований по компьютерной лингвистике

# Диалектные и нестандартные варианты русского языка



## Стратегии по производству корпуса

- Чаще всего мы не собирали корпуса, а заключали договор с теми, кто его собирал, чтобы подготовить разметку:
  - в формате .TextGrid или .eaf;
  - на литературном русском.

## Стратегии по производству корпуса

- Чаще всего мы не собирали корпуса, а заключали договор с теми, кто его собирал, чтобы подготовить разметку:
  - в формате .TextGrid или .eaf;
  - на литературном русском.
- В результате:
  - в поисковом запросе мы найдем нечто общее вне зависимости от фонетических, дискурсивных и морфсинтаксических особенностей;
  - будет работать NLP для литературного русского.

## Стратегии по производству корпуса

- Чаще всего мы не собирали корпуса, а заключали договор с теми, кто его собирал, чтобы подготовить разметку:
  - в формате .TextGrid или .eaf;
  - на литературном русском.
- В результате:
  - в поисковом запросе мы найдем нечто общее вне зависимости от фонетических, дискурсивных и морфсинтаксических особенностей;
  - будет работать NLP для литературного русского.
- Недавно мы опубликовали три копруса, которые были сделаны по-другому:
  - исследователь из лаборатории собирает аудио
  - запускаем модель распознавания речи (whisper)
  - студенты проверяют работу модели в качестве практики
  - сотрудники лаборатории проверяют после студентов

## Что делать со всеми этими корпусами?

- ожидания: серия связанных исследований с похожей методологией количественного моделирования вариативности появления нестандартных форм
- реальность: очень сложно найти теоретически осмысленное объединение для билингвального и диалектного материала

## Что делать со всеми этими корпусами?

- ожидания: серия связанных исследований с похожей методологией количественного моделирования вариативности появления нестандартных форм
- реальность: очень сложно найти теоретически осмысленное объединение для билингвального и диалектного материала
- В результате мы опубликовали ряд исследований, разделяя
  - билингвальное [Grishanova, 2025, Naccarato and Moroz, 2025, Яковлева, 2025, Yakovleva et al., 2025]
  - и диалектное [Ермолова and Мороз, 2024, Земичева et al., 2025]
- Ход таких исследований:
  - выбрать лингвистический признак
  - автоматически извлечь все контексты, используя морфологическую (mystem) и синтаксическую (udpipe) разметки
  - переслушать в случаях, когда есть основания не доверять разметке (например, модель может вставить предлог)
  - статистически моделировать вероятность появления нестандартной формы в зависимости от лингвистических и социолингвистических параметров

## Что делать со всеми этими корпусами?

- ожидания: серия связанных исследований с похожей методологией количественного моделирования вариативности появления нестандартных форм
- в качестве основы надо брать нечто, что вариативно уже в литературном русском
  - ударение (на́ голову vs. на го́лову; забра́ла vs. забралá)
  - интонация
  - ...
- Но все равно объяснения будут носить разный характер:
  - диалектная вариативность будет объясняться процессами в истории русского языка, хотя и можно пытаться измерить степень влияния литературного варианта
  - билингвальная вариативность будет объясняться борьбой эффектов влияния L1 и неидельного освоения

## Частотность как переменная

- В [Naccarato and Moroz, 2025] мы обнаружили, что нестандартных форм в конструкциях с числительными меньше, если сочетание имени и числительного частотно (*два года* vs. *два канделябра*).
- Данный эффект не был статистически значим в исследованиях выпадения предлога [Grishanova, 2025, Яковлева, 2025], мы обнаружили, что значимым фактором является фонетика и социолингвистика.
- Несмотря на это, стоит всегда иметь это в виду и API НКРЯ теперь значительно облегчает определение частотности не только отдельного слова, но и целой конструкции или даже группы конструкций, а также позволяет анализировать разбивку частотности по годам.

## Частотность как переменная

- В [Naccarato and Moroz, 2025] мы обнаружили, что нестандартных форм в конструкциях с числительными меньше, если сочетание имени и числительного частотно (*два года* vs. *два канделябра*).
- Данный эффект не был статистически значим в исследованиях выпадения предлога [Grishanova, 2025, Яковлева, 2025], мы обнаружили, что значимым фактором является фонетика и социолингвистика.
- Несмотря на это, стоит всегда иметь это в виду и API НКРЯ теперь значительно облегчает определение частотности не только отдельного слова, но и целой конструкции или даже группы конструкций, а также позволяет анализировать разбивку частотности по годам.
- (Если кому-то нужно, вот мой скрипт для обработки запросов API НКРЯ на R.)



## Частотность как переменная

В одном проекте мы анализируем заимствования из русского языка в аваро-андийских языках. Мы ожидаем, что поздние заимствования будут меньше фонологически адаптироваться по сравнению со старыми:

- s:ukuna ‘сукно’ (годоберинский, [Саидова, 2006])
- ʃamɾun ‘шампунь’ (годоберинский, [Саидова, 2006])

Но как же нам разделить слова на старые и новые?

- Есть словарь советской лексики [Мокиенко and Никитина, 1998]

## Частотность как переменная

В одном проекте мы анализируем заимствования из русского языка в аваро-андийских языках. Мы ожидаем, что поздние заимствования будут меньше фонологически адаптироваться по сравнению со старыми:

- s:ukuna ‘сукно’ (годоберинский, [Саидова, 2006])
- ʃamɾun ‘шампунь’ (годоберинский, [Саидова, 2006])

Но как же нам разделить слова на старые и новые?

- Есть словарь советской лексики [Мокиенко and Никитина, 1998], он покрывает 21% (239 из 1345) наших данных

## Частотность как переменная


В одном проекте мы анализируем заимствования из русского языка в аваро-андийских языках. Мы ожидаем, что поздние заимствования будут меньше фонологически адаптироваться по сравнению со старыми:

- sɜːkuna ‘сукно’ (годоберинский, [Саидова, 2006])
- ʃamɾun ‘шампунь’ (годоберинский, [Саидова, 2006])


Но как же нам разделить слова на старые и новые?

- Есть словарь советской лексики [Мокиенко and Никитина, 1998], он покрывает 21% (239 из 1345) наших данных
- Можно использовать частотность из НКРЯ!
  - мы выкачиваем разбивку по годам из НКРЯ
  - считаем кумулятивную сумму
  - выбираем пороговое значение

## Частотность как переменная




## Частотность как переменная



Можно использовать не абсолютн. частотность, а количество текстов

## Частотность как переменная



Пороговое значение — 10%.

# Проекты по исследованию языков Кавказа

## Исследования абхазо-адыгских языков

- большие письменные корпуса
- маленькие устные диалектные корпуса
- ежегодные экспедиции



# Typological Atlas of the Languages of Daghestan

WALS, но для языков Дагестана.

- <https://lingconlab.ru/tald/>
- DEV-версия <https://lingconlab.github.io/TALD>
- [contributor manual](#)
- более 70 глав (фонология, морфология, лексика, синтаксис, дискурс) и несколько видов карт
- открытые данные, покрытые тестами

## Дигитализация нахско-дагестанских словарей

Большой проект лаборатории начался с лексикографической базы данных андийских языков:

- [Moroz et al., 2025]:
  - лемма
  - представление в IPA;
  - морфологические особенности (например, множественное число, класс или глагольные формы);
  - части речи;
  - толкование;
  - отдельные значения леммы;
  - примеры;
  - предполагаемый источник заимствования;
  - когнатность на основе [Мудрак, 2020].

Сейчас база данных пополняется аварским, нахскими и цезскими языками.

## Рутульский проект

Проект начинался как проект по описанию кининского говора рутульского языка (планируется издать сборник статей).

В 2022 году был собран материал в 12 селах и оформлен **в атлас**, в котором более чем 400 признаков. Анкеты на разные домены:

- стословники (~ Swadesh 200 / CoBL);
- дополнительная лексика;
- фонетика и фонология;
- морфология;
- синтаксис;
- дискурсивные формулы.

Кроме того, был составлен электронный словарь (версия **один**, версия **два**). Каждый вход содержит словоизменительную информацию, список возможных значений и сентенциальные примеры для каждого значения.

## The Caucasian languages. An International Handbook

В издательстве De Gruyter Mouton запланирован сборник «The Caucasian languages. An International Handbook» в трех томах под редакцией Т. А. Майсака, Ю. Б. Корякова, С. Кея, Ю. А. Ландера:

- Nakh-Daghestanian languages: Nakh, Avar-Andic and Tsezic
- Nakh-Daghestanian languages: Lak, Dargwa, Lezgian and Khinalug
- West Caucasian languages. Kartvelian languages

Все статьи имеют сходную структуру.

## Векторный поиск по сборнику

Статьи из сборника «The Caucasian languages. An International Handbook» достаточно легко использовать как базу данных для векторного поиска.

### Посредственный поисковик

- представить тексты в едином формате (.docx -> markdown)
- разделить тексты на небольшие пересекающиеся кусочки
- векторизовать полученные фрагменты
- векторизовать запрос и найти ближайшие на основе косинусного расстояния

### Генерация, дополненная поиском (aka RAG)

- дать результаты запроса LLM для обобщения

## Векторный поиск по лингвистическим аннотациям

Мы в какой-то момент собирали базу данных аннотаций статей по лингвистике.

- англоязычные (79 тысяч) 626012700078-5
- русскоязычные (19 тысяч) 626012700079-2

Спасибо за внимание!

## Ссылки на литературу I

- A. Grishanova. An overview of morphosyntactic variation in the speech of Russian-Chuvash bilinguals: number, gender, case assignment and preposition drop. *Russian Linguistics*, 49, 2025. doi: 10.1007/s11185-025-09318-6.
- G. Moroz, A. Antsupova, A. Averin, D. Chistyakova, K. Chuprinko, A. Davidenko, M. Dolgodvorova, N. Fedorenko, T. Gnedina, G. Kuznetsov, S. Kuznetsova, C. Naccarato, I. Sadakov, Z. Shkutko, A. Tsyzoza, S. Verhees, and V. Zubkova. *Comparative Andic dictionary database*. Linguistic Convergence Laboratory, HSE University, Moscow, apr 2025. doi: 10.5281/zenodo.15253237. URL <https://doi.org/10.5281/zenodo.15253237>.
- C. Naccarato and G. Moroz. Non-standard numeral constructions in L2 Russian: A corpus-based study. *International Journal of Bilingualism*, 2025.



## Ссылки на литературу II

- A. Yakovleva, N. Koshelyuk, and G. Moroz. Preposition drop in Russian spoken by Mari and Besermyan bilinguals. *International Journal of Bilingualism*, 2025.
- М. В. Ермолова and Г. А. Мороз. Отпричастные *-ши-* формы в двух псковских и одном смоленском говорах: сопоставление подсистем. *Slověne*, 13(2):157–183, 2024. doi: 10.31168/2305-6754.2024.2.06.
- С. С. Земичева, Г. А. Мороз, and К. Наккарато. Вариативность *годов* vs. *лет* в русских говорах: корпусное исследование. *Вопросы языкознания*, (6):7–34, 2025.
- В. М. Мокиенко and Т. Г. Никитина. *Толковый словарь языка Совдепии*. Фолио-пресс, Санкт-Петербург, 1998.

## Ссылки на литературу III

- О. А. Мудрак. *Андийские основы: Этимологический словарь*. Языки Народов Мира, Москва, 2020.
- П. А. Саидова. *Годоберинско-русский словарь*. ДНЦ РАН, Махачкала, 2006.
- А. В. Яковлева. Опускание предлогов в русской речи марийских и бесермянских билингвов: исследование на основе устных корпусов. *Труды института русского языка им. В.В. Виноградова*, 46(4):264–285, 2025. doi: 10.31912/pvrli-2025.4.11.