

Проекты Международной лаборатории языковой конвергенции

Семинар Школы лингвистики

Г. А. Мороз

30.01.2026

О лаборатории

Международная лаборатория языковой конвергенции

- Открыта в 2017 году



(а) Н. Р. Добрушина



(а) Дж. Николс

Оба исследователя специализируются на славянских языках и языках Кавказа, а также лингвистической типологии

Ресурсы лаборатории

У истоков проекта

- Многолетние социолингвистические поездки в Дагестан
- Несколько диалектных экспедиций в Устьянский район
- Онлайн ресурсы, появившиеся в результате:
 - Корпус дагестанского русского
 - Корпус устьянских говоров
 - ... другие диалектные и билингвальные корпуса

Ресурсы лаборатории

У истоков проекта

- Многолетние социолингвистические поездки в Дагестан
- Несколько диалектных экспедиций в Устьянский район
- Онлайн ресурсы, появившиеся в результате:
 - Корпус дагестанского русского
 - Корпус устьянских говоров
 - ... другие диалектные и билингвальные корпуса

Сейчас

- <https://lingconlab.ru/>
- 28 диалектных корпусов
- 10 билингвальных корпусов
- 17 корпусов языков России
- 6 словарей языков России
- 8 лингвистических баз данных

Ресурсы лаборатории

У истоков проекта

- Многолетние социолингвистические поездки в Дагестан
- Несколько диалектных экспедиций в Устьянский район
- Онлайн ресурсы, появившиеся в результате:
 - Корпус дагестанского русского
 - Корпус устьянских говоров
 - ... другие диалектные и билингвальные корпуса

Сейчас

- <https://lingconlab.ru/>
- 28 диалектных корпусов
- 10 билингвальных корпусов
- 17 корпусов языков России
- 6 словарей языков России
- 8 лингвистических баз данных

И мы ищем людей, которые бы все это поддерживали!

Наши исследования

- Исследования диалектных и нестандартных вариантов русского языка
- Документация и исследования языков Кавказа
- Ассирийские исследования
- Типологические и микротипологические исследования
- Есть потенциал для исследований по компьютерной лингвистике

Диалектные и нестандартные варианты русского языка

Стратегии по производству корпуса

- Чаще всего мы не собирали корпусов, а заключали договор с теми, кто его собирал, чтобы подготовить разметку:
 - в формате .TextGrid или .eaf;
 - на литературном русском.

Стратегии по производству корпуса

- Чаще всего мы не собирали корпусов, а заключали договор с теми, кто его собирал, чтобы подготовить разметку:
 - в формате .TextGrid или .eaf;
 - на литературном русском.
- В результате:
 - в поисковом запросе мы найдем нечто общее вне зависимости от фонетических, дискурсивных и морфсинтаксических особенностей;
 - будет работать NLP для литературного русского.

Стратегии по производству корпуса

- Чаще всего мы не собирали корпусов, а заключали договор с теми, кто его собирал, чтобы подготовить разметку:
 - в формате .TextGrid или .eaf;
 - на литературном русском.
- В результате:
 - в поисковом запросе мы найдем нечто общее вне зависимости от фонетических, дискурсивных и морфсинтаксических особенностей;
 - будет работать NLP для литературного русского.
- Недавно мы опубликовали три копруса, которые были сделаны по-другому:
 - исследователь из лаборатории собирает аудио
 - запускаем модель распознавания речи (whisper)
 - студенты проверяют работу модели в качестве практики
 - сотрудники лаборатории проверяют после студентов

Что делать со всеми этими корпусами?

- ожидания: серия связанных исследований с похожей методологией количественного моделирования вариативности появления нестандартных форм
- реальность: очень сложно найти теоретически осмысленное объединение для билингвального и диалектного материала

Что делать со всеми этими корпусами?

- ожидания: серия связанных исследований с похожей методологией количественного моделирования вариативности появления нестандартных форм
- реальность: очень сложно найти теоретически осмысленное объединение для билингвального и диалектного материала
- В результате мы опубликовали ряд исследований, разделяя
 - билингвальное [Grishanova, 2025, Naccarato and Moroz, 2025, Яковлева, 2025, Yakovleva et al., 2025]
 - и диалектное [Ермолова and Мороз, 2024, Земичева et al., 2025]
- Ход таких исследований:
 - выбрать лингвистический признак
 - автоматически извлечь все контексты, используя морфологическую (mystem) и синтаксическую (udpipe) разметки
 - переслушать в случаях, когда есть основания не доверять разметке (например, модель может вставить предлог)
 - статистически моделировать вероятность появления нестандартной формы в зависимости от лингвистических и социолингвистических параметров

Что делать со всеми этими корпусами?

- ожидания: серия связанных исследований с похожей методологией количественного моделирования вариативности появления нестандартных форм
- в качестве основы надо брать нечто, что вариативно уже в литературном русском
 - ударение (на́ голову vs. на го́лову; забра́ла vs. забралá)
 - интонация (кстати обратите внимание на проект [PRuD](#))
 - ...
- Но все равно объяснения будут носить разный характер:
 - Диалектная вариативность будет объясняться процессами в истории русского языка, хотя и можно пытаться измерить степень влияния литературного варианта
 - билингвальная вариативность будет объясняться борьбой эффектов влияния L1 и неидеального освоения

Частотность как переменная

- В [Naccarato and Moroz, 2025] мы обнаружили, что нестандартных форм в конструкциях с числительными меньше, если сочетание имени и числительного частотно (*два года* vs. *два канделябра*).
- Данный эффект не был статистически значим в исследованиях выпадения предлога [Grishanova, 2025, Яковлева, 2025], мы обнаружили, что значимым фактором является фонетика и социолингвистика.
- Несмотря на это, стоит всегда иметь это в виду и API НКРЯ теперь значительно облегчает определение частотности не только отдельного слова, но и целой конструкции или даже группы конструкций, а также позволяет анализировать разбивку частотности по годам.

Частотность как переменная

- В [Naccarato and Moroz, 2025] мы обнаружили, что нестандартных форм в конструкциях с числительными меньше, если сочетание имени и числительного частотно (*два года* vs. *два канделябра*).
- Данный эффект не был статистически значим в исследованиях выпадения предлога [Grishanova, 2025, Яковлева, 2025], мы обнаружили, что значимым фактором является фонетика и социолингвистика.
- Несмотря на это, стоит всегда иметь это в виду и API НКРЯ теперь значительно облегчает определение частотности не только отдельного слова, но и целой конструкции или даже группы конструкций, а также позволяет анализировать разбивку частотности по годам.
- (Если кому-то нужно, вот мой скрипт для обработки запросов API НКРЯ на R.)

Частотность как переменная

В одном проекте мы анализируем заимствования из русского языка в аваро-андийских языках. Мы ожидаем, что поздние заимствования будут меньше фонологически адаптироваться по сравнению со старыми:

- sɜːkuna ‘сукно’ (годоберинский, [Саидова, 2006])
- ʃamɾun ‘шампунь’ (годоберинский, [Саидова, 2006])

Но как же нам разделить слова на старые и новые?

- Есть словарь советской лексики [Мокиенко and Никитина, 1998]

Частотность как переменная

В одном проекте мы анализируем заимствования из русского языка в аваро-андийских языках. Мы ожидаем, что поздние заимствования будут меньше фонологически адаптироваться по сравнению со старыми:

- sʰukuna ‘сукно’ (годоберинский, [Саидова, 2006])
- ʃamɾun ‘шампунь’ (годоберинский, [Саидова, 2006])

Но как же нам разделить слова на старые и новые?

- Есть словарь советской лексики [Мокиенко and Никитина, 1998], он покрывает 21% (239 из 1345) наших данных

Частотность как переменная


В одном проекте мы анализируем заимствования из русского языка в аваро-андийских языках. Мы ожидаем, что поздние заимствования будут меньше фонологически адаптироваться по сравнению со старыми:

- sʰukuna ‘сукно’ (годоберинский, [Саидова, 2006])
- ʃamɾun ‘шампунь’ (годоберинский, [Саидова, 2006])


Но как же нам разделить слова на старые и новые?

- Есть словарь советской лексики [Мокиенко and Никитина, 1998], он покрывает 21% (239 из 1345) наших данных
- Можно использовать частотность из НКРЯ!
 - мы выкачиваем разбивку по годам из НКРЯ
 - считаем кумулятивную сумму
 - выбираем пороговое значение

Частотность как переменная




Частотность как переменная



Можно использовать не абсолютн. частотность, а количество текстов

Частотность как переменная



Пороговое значение — 10% от начала.

Проекты по исследованию языков Кавказа

Исследования абхазо-адыгских языков

- большие письменные корпуса
- маленькие устные диалектные корпуса
- ежегодные экспедиции

Typological Atlas of the Languages of Daghestan

WALS, но для языков Дагестана.

- <https://lingconlab.ru/tald/>
- DEV-версия <https://lingconlab.github.io/TALD>
- [contributor manual](#)
- более 70 глав (фонология, морфология, лексика, синтаксис, дискурс) и несколько видов карт
- открытые данные, покрытые тестами

Дигитализация нахско-дагестанских словарей

Большой проект лаборатории начался с лексикографической базы данных андийских языков:

- [Moroz et al., 2025]:
 - лемма
 - представление в IPA;
 - морфологические особенности (например, множественное число, класс или глагольные формы);
 - части речи;
 - толкование;
 - отдельные значения леммы;
 - примеры;
 - предполагаемый источник заимствования;
 - когнатность на основе [Мудрак, 2020].

Сейчас база данных пополняется аварским, нахскими и цезскими языками.

Рутульский проект

Проект начинался как проект по описанию кининского говора рутульского языка (планируется издать сборник статей).

В 2022 году был собран материал в 12 селах и оформлен в атлас, в котором более чем 400 признаков. Анкеты на разные домены:

- стословники (~ Swadesh 200 / CoBL);
- дополнительная лексика;
- фонетика и фонология;
- морфология;
- синтаксис;
- дискурсивные формулы.

Кроме того, был составлен электронный словарь (версия один, версия два). Каждый вход содержит словоизменительную информацию, список возможных значений и сентенциальные примеры для каждого значения.

The Caucasian languages. An International Handbook

В издательстве De Gruyter Mouton запланирован сборник «The Caucasian languages. An International Handbook» в трех томах под редакцией Т. А. Майсака, Ю. Б. Корякова, С. Кея, Ю. А. Ландера:

- Nakh-Daghestanian languages: Nakh, Avar-Andic and Tsezic
- Nakh-Daghestanian languages: Lak, Dargwa, Lezgian and Khinalug
- West Caucasian languages. Kartvelian languages

Все статьи имеют сходную структуру.

Векторный поиск по сборнику

Статьи из сборника «The Caucasian languages. An International Handbook» достаточно легко использовать как базу данных для векторного поиска.

Посредственный поисковик

- представить тексты в едином формате (.docx -> markdown)
- разделить тексты на небольшие пересекающиеся кусочки
- векторизовать полученные фрагменты
- векторизовать запрос и найти ближайшие на основе косинусного расстояния

Генерация, дополненная поиском (aka RAG)

- дать результаты запроса LLM для обобщения

Векторный поиск по лингвистическим аннотациям

Мы в какой-то момент собирали базу данных аннотаций статей по лингвистике.

- англоязычные (79 тысяч) 626012700078-5
- русскоязычные (19 тысяч) 626012700079-2

Заключение

Заключение

- Корпусная лингвистика еще много может нам рассказать
 - хвала API НКРЯ!

Заклучение

- Корпусная лингвистика еще много может нам рассказать
 - хвала API НКРЯ!
- Русский перевод открывает богатые возможности трансфера NLP инструментов для русского языка на корпуса и словари малоресурсных языков

Заключение

- Корпусная лингвистика еще много может нам рассказать
 - хвала API НКРЯ!
- Русский перевод открывает богатые возможности трансфера NLP инструментов для русского языка на корпуса и словари малоресурсных языков
- LLM уже сидят на зубах, но хорошо бы не пропустить революцию
 - следует копить не только необработанные данные (звук, корпуса, словари), но и научные работы

Спасибо за внимание!

Ссылки на литературу I

- A. Grishanova. An overview of morphosyntactic variation in the speech of Russian-Chuvash bilinguals: number, gender, case assignment and preposition drop. *Russian Linguistics*, 49, 2025. doi: 10.1007/s11185-025-09318-6.
- G. Moroz, A. Antsupova, A. Averin, D. Chistyakova, K. Chuprinko, A. Davidenko, M. Dolgodvorova, N. Fedorenko, T. Gnedina, G. Kuznetsov, S. Kuznetsova, C. Naccarato, I. Sadakov, Z. Shkutko, A. Tsyzoza, S. Verhees, and V. Zubkova. *Comparative Andic dictionary database*. Linguistic Convergence Laboratory, HSE University, Moscow, apr 2025. doi: 10.5281/zenodo.15253237. URL <https://doi.org/10.5281/zenodo.15253237>.
- C. Naccarato and G. Moroz. Non-standard numeral constructions in L2 Russian: A corpus-based study. *International Journal of Bilingualism*, 2025.

Ссылки на литературу II

- A. Yakovleva, N. Koshelyuk, and G. Moroz. Preposition drop in Russian spoken by Mari and Besermyan bilinguals. *International Journal of Bilingualism*, 2025.
- М. В. Ермолова and Г. А. Мороз. Отпричастные *-ши-* формы в двух псковских и одном смоленском говорах: сопоставление подсистем. *Slověne*, 13(2):157–183, 2024. doi: 10.31168/2305-6754.2024.2.06.
- С. С. Земичева, Г. А. Мороз, and К. Наккарато. Вариативность *годов* vs. *лет* в русских говорах: корпусное исследование. *Вопросы языкознания*, (6):7–34, 2025.
- В. М. Мокиенко and Т. Г. Никитина. *Толковый словарь языка Совдепии*. Фолио-пресс, Санкт-Петербург, 1998.

Ссылки на литературу III

- О. А. Мудрак. *Андийские основы: Этимологический словарь*. Языки Народов Мира, Москва, 2020.
- П. А. Саидова. *Годоберинско-русский словарь*. ДНЦ РАН, Махачкала, 2006.
- А. В. Яковлева. Опускание предлогов в русской речи марийских и бесермянских билингвов: исследование на основе устных корпусов. *Труды института русского языка им. В.В. Виноградова*, 46(4):264–285, 2025. doi: 10.31912/pvrl-2025.4.11.